

Resumen de Propuestas de TFM

Vision General

Se tienen 4 propuestas de TFM provenientes de distintas entidades/empresas, con un total de 9 proyectos posibles:

Propuesta	Area	Dificultad	Stack principal
AFT/IAmotions (UCM)	Interpretabilidad IA + Linguistica	Alta (investigacion)	Python, modelos open-weight, estadistica
IMDEA Materials	RAG + Metadatos cientificos	Media-Alta	Python, Ollama, pgvector, RAG
Sandoz (x3)	IA aplicada a farma/finanzas	Media	Python, LLMs, ML, scraping
TUI (x4)	Turismo + NLP + Dashboards	Media	Python, NLP, dashboards, scraping

1. AFT e IAmotions (UCM - Proyecto academico)

Que es

Validar empiricamente una teoria nueva llamada Almotional Field Theory (AFT) que propone que los modelos de lenguaje (LLMs) presentan patrones dinamicos internos recurrentes cuando procesan texto ambiguo, especialmente poesia.

El marco general se llama IA2IAh (Humano -> IA -> IA -> Humano) y estudia circuitos de interpretacion entre humanos y modelos de lenguaje.

AFT NO afirma que las maquinas tengan emociones. Propone que los LLMs podrian presentar patrones dinamicos internos medibles que pueden describirse como regiones o regimenes dentro de un espacio dinamico.

Estructura en dos fases

Fase 1: AFT8 (Nucleo falsable) - 8 dimensiones

Codigo	Dimension	Funcion
DeltaP	Cambio predictivo	Mide revision de expectativa (divergencia JS)
DeltaE	Cambio de entropia	Mide apertura/estrechamiento del campo predictivo
GxA	Saliencia causal	Gradient x Attention, sustituye atencion cruda
C*	Anclaje contextual normalizado	Dependencia del contexto previo, normalizada
N*	Novedad por bancos de referencia	Distancia a bancos explicitos
Phi*	Desacuerdo predictivo interno	Conflicto entre contribuciones internas
Pi*	Persistencia acumulada	Autocorrelacion con decay exponencial
B*	Ambiguedad de frontera	Se calcula tras clustering

Fase 2: AFT15 (Solo si AFT8 sobrevive)

Expandir a 15 dimensiones anadiendo:

- DeltaA (Cambio de activaciones)
- LSS (Layer Specialization Shift)
- DeltaT (Persistencia local)
- L* (Brecha local-global)
- SCI (Semantic Compression Index)
- IM (Inhibitory Momentum)
- PHT (Predictive Hierarchy Tension)

IAmotions (16 regimenes candidatos)

Regimenes dinamicos con puente funcional a emociones humanas:

Codigo	Nombre	Emocion correlativa
CP	Contraccion Predictiva	Miedo; Anticipacion
ID	Intensificacion Directiva	Ira; Anticipacion
EI	Eco Interno	Tristeza; Confianza
RA	Reorientacion Abrupta	Sorpresa
IS	Inhibicion Semantica	Tristeza; Aversion debil
ER	Estabilizacion Resonante	Confianza
AG	Apertura Generativa	Alegria; Anticipacion
DI	Dispersion Interpretativa	Alegria; Sorpresa
EE	Expansion Estocastica	Sorpresa; Alegria
SE	Saturacion de Entropia	Sorpresa; Aversion
DP	Desacoplamiento Preventivo	Miedo; Aversion
ISem	Inhibicion Semantica Defensiva	Asco/Aversion
CA	Consistencia Auto-reforzada	Confianza
DR	Deriva Resonante	Tristeza; Confianza
TS	Transferencia de Saliencia	Sorpresa
SG	Sincronizacion Gradual	Confianza; Alegria

Que hacer concretamente

Bloque tecnico IA:

- Desplegar modelos open-weight (Llama, Mistral, etc.)
- Extraer logits, hidden states, atencion y gradientes token a token
- Construir pipeline AFT8 que calcule las 8 dimensiones
- Medir estabilidad, separabilidad y robustez

Bloque experimental:

- Comparar poesia densa, poesia plana y controles
- Diseñar perturbaciones minimas y tests adversariales
- Controlar decoding y normalizacion
- Decidir con datos si AFT8 merece escalar a AFT15

Bloque analisis:

- Anotacion humana ciega a AFT
- Baselines: aleatorio isomorfo + PCA/ICA + metricas simples
- Criterios go/no-go pre-registrados

Dataset requerido

Fase 1: 360 textos base, 720 variantes

- Set A: 120 textos de poesia densa (maxima ambigüedad)
- Set B: 120 textos de poesia plana pareada (mismo contenido, mas literal)
- Set C: 120 textos no-poeticos (prosa tecnica, controles)
- Set D: Adversarial/perturbaciones derivadas de A

Perturbaciones estandar por texto:

- P1: Parafrasis minima
- P2: Cambio de puntuacion
- P3: Cambio de verso
- P4: Sustitucion metaforica local
- P5: Giro ontologico localizado
- P6: Control negativo matched

Fase 2: 300 textos base, 600 variantes (5 subconjuntos E1-E5)

Control de decoding

Condicion	Temperatura	top-p	Seeds
Greedy	0	n/a	1
Sampling-1	0.7	0.9	5
Sampling-2	1.0	0.9	5

Principios operativos

- Modelos open-weights instrumentables
- Dominio empirico prioritario: poesia (con controles no poeticos)
- Validacion inicial mono-modelo
- Toda decision congelada antes de ver resultados
- Cada afirmacion fuerte debe tener test de falsacion y baseline negativo

Herramientas

Python, modelos open-weight (Llama, Mistral), PyTorch, interpretabilidad (Gradient x Attention, logit lens), estadística (bootstrap, ANOVA jerarquica), control de seeds

Horizonte temporal: Jun-Sep 2026

2. IMDEA Materials

Que es

Desarrollar un asistente de IA local para extraccion automatica de metadatos y busqueda semantica en sistemas de gestion de datos cientificos.

Pregunta de investigacion

Hasta que punto pueden los LLMs locales y open-source automatizar la extraccion de metadatos y la recuperacion semantica sobre datos cientificos heterogeneos, y como se comparan con APIs cloud en precision, latencia y coste?

Contexto

- Plataforma FAIR-LAB en IMDEA Materials
- Principios FAIR (Findable, Accessible, Interoperable, Reusable)
- Areas: manufactura aditiva, tomografia de rayos X

Que hacer

Core (obligatorio):

- Extraccion de metadatos de un tipo de archivo principal
- Generacion y almacenamiento de metadatos estructurados
- Busqueda semantica usando embeddings en pgvector (PostgreSQL)

Extensiones (opcionales):

- Asistente RAG para consultas en lenguaje natural
- Benchmarking de modelos locales entre si y vs cloud
- Soporte para tipos de archivo adicionales

Pipeline propuesto

Archivos cientificos (PDF, CSV, logs) -> Pipeline extraccion (Python, OCR) -> Embeddings (modelo local) -> Vector DB (pgvector/FAISS/Chroma) -> Sistema RAG -> LLM local (Ollama: Llama, Mistral, Qwen)

Herramientas

Python, OCR, Ollama (Llama/Mistral/Qwen), pgvector/PostgreSQL, FAISS/Chroma, RAG frameworks

3. SANDOZ (3 propuestas farmaceuticas)

3a. AutoComments

Sistema de IA que genera automaticamente comentarios de reporting financiero (variance analysis) para management reporting.

Problema: Proceso manual, consume tiempo, requiere expertise senior, genera inconsistencias.

Que hacer:

1. Data Understanding: Analizar datos contables (geografia, producto, cliente, periodo)
2. Driver Identification: Reglas analiticas y/o ML para detectar contribuyentes a varianzas
3. Natural Language Generation: Generar texto estructurado tipo business
4. Validation: Evaluar contra comentarios manuales con stakeholders

Herramientas: Python, LLMs, bases de datos financieras

Referentes: Amazon Insights Agent, DataSage (ByteDance)

3b. PriceErosion

Predecir la erosion de precios de biosimilares a nivel SKU usando IA.

Problema: Biosimilares sufren erosion por competencia. Entender velocidad y magnitud de caida es critico.

Que hacer:

- Construir modelos predictivos de ML para forecast de precios
- Identificar key price drivers por mercado
- Integrar LLM para explicar predicciones en lenguaje natural

Datos: Historicos anonimizados de ventas y precios a nivel SKU

Herramientas: Python, ML (scikit-learn, XGBoost), LLMs

3c. The Extractor

Bot de IA para scraping y extraccion de datos farmaceuticos de webs regulatorias.

Problema: Datos criticos dispersos en EMA, FDA en formato no estructurado.

Que hacer:

- Descargar datos de sitios regulatorios (EMA, FDA)
- Extraer informacion relevante de documentos
- Estructurar segun formato interno Sandoz
- Proveer trazabilidad (fuente + pagina para validacion humana)

Herramientas: Python, LLMs, web scraping, APIs, parsers

4. TUI (Turismo - 4 desafios)

Contexto TUI

- Grupo turistico lider mundial (34.7M clientes, 180 paises)
- Revenue 2025: 24.2 bn EUR
- Foco en sostenibilidad y reduccion de concentracion turistica
- Programa: Fernando Tapiador (Programme Manager T8.9)
- Horizonte: 2/2026 (segundo semestre)

4a. Monitor de Ofertas Experienciales & Tendencias de Sentimiento

Problema: Destinos no comprenden en tiempo real que experiencias generan interes o frustracion.

Objetivo: Plataforma de inteligencia turistica que analice conversaciones digitales.

Fuentes: Instagram, TikTok, X, Reddit, Google Reviews, TripAdvisor, Booking, YouTube, foros, contenido IA

Metodologia:

5. Recoleccion multifuente
6. Limpieza multilingue
7. Sentiment analysis y emotion detection
8. Topic modeling
9. Clustering de experiencias
10. Georreferenciacion
11. Identificacion oportunidades
12. Visualizacion e insights

Modelos: Multilingual BERT, XLM-RoBERTa, Sentence-BERT, BERTopic, LLMs, Zero-Shot

Dashboard: Power BI, Tableau, Streamlit o Looker Studio

Entregables: Prototipo, pipeline, dashboard, informe, mapa de oportunidades

4b. Motor de Recomendaciones & Redistribucion de Demanda

Problema: 85% de turistas visitan solo 10% del destino. Zonas rurales a 40-50% capacidad.

Objetivo: IA predictiva para redistribuir flujos turisticos con recomendaciones personalizadas.

4c. Mapas de Accesibilidad & Movilidad Sostenible

Objetivo: IA + datos georreferenciados para mapear accesibilidad y rutas sostenibles e inclusivas.

4d. AI-Dashboard Oferta Turistica Georreferenciada

Objetivo: Integracion con datos abiertos para gestion inteligente de oferta turistica.

Comparativa para Decision

Criterio	AFT (UCM)	IMDEA	Sandoz	TUI
Tipo de trabajo	Investigacion pura	Ingenieria + invest.	Ingenieria aplicada	Ingenieria aplicada
Riesgo	Alto (result. negativo)	Medio	Bajo	Bajo-Medio
Publicabilidad	Alta (paper)	Media	Baja	Baja-Media
Contacto empresa	No (academico)	Si (IMDEA)	Si (Sandoz/Novartis)	Si (TUI Group)
Complejidad tecnica	Muy alta	Alta	Media	Media
Claridad scope	Muy definido	Bien definido	Bien definido	Amplio
Valor CV corporativo	Bajo	Alto (ciencia)	Alto (farma)	Alto (turismo)
Originalidad	Muy alta	Media	Media	Media
Recursos necesarios	GPU, open-weight	Servidor, PostgreSQL	Datos Sandoz, LLMs	APIs, scraping
Documentacion dada	Muy extensa (475+ pag)	Minima (3 pag)	Minima (2 pag c/u)	Buena (55+ pag)