

UNIVERSIDAD COMPLUTENSE DE MADRID

FACULTAD DE CIENCIAS DE LA DOCUMENTACIÓN



MÁSTER DATA SCIENCE, BIG DATA & BUSINESS ANALYTICS

TRABAJO FIN DE MÁSTER

CURSO 2024-2025

**REDESCUBRIENDO ESPAÑA: ANÁLISIS DE SENTIMIENTOS
PARA UN TURISMO SOSTENIBLE MEDIANTE UN
RECOMENDADOR INTELIGENTE**

AUTORES:

Jhon Emerson Medina Osis

Maripi Antuanet Mendieta Aguilar

Kiana Katy Paco Andrade

Sebastián Soto Marín

Eduardo David Temoche Solano

Cynthia Estela Vásquez Bravo

RESUMEN EJECUTIVO

Este proyecto presenta el desarrollo de un sistema inteligente de recomendación turística basado en el análisis de sentimientos de reseñas reales extraídas de plataformas como TripAdvisor y Reddit. A través de técnicas de procesamiento de lenguaje natural (NLP), se clasifican las opiniones en dos categorías: “Molestia” y “No molestia”, lo que permite identificar experiencias negativas o positivas asociadas a destinos turísticos en España.

La metodología utilizada sigue el enfoque CRISP-DM (Cross Industry Standard Process for Data Mining), estructurando el proyecto en fases iterativas que incluyen la comprensión del negocio, la preparación de los datos, el modelado y la evaluación. En particular, el proceso de recolección de datos se implementó mediante técnicas de web scraping, organizadas bajo el paradigma ETL (Extract, Transform, Load), que permitió extraer información de múltiples fuentes, transformarla mediante limpieza y normalización lingüística, y cargarla en un entorno de análisis en la nube.

Para el modelado, se ha entrenado un sistema multimodal utilizando XLM-RoBERTa-base, ajustado para la clasificación binaria de sentimientos, en combinación con variables contextuales como destino turístico, mes y día de la semana. Este enfoque permite capturar tanto el contenido semántico de las reseñas como el contexto temporal en el que se producen.

Finalmente, se ha desarrollado un sistema de recomendación que, en función del nivel de saturación turística y la proporción de reseñas positivas, sugiere destinos alternativos cercanos con mejor reputación. El sistema se presenta mediante una interfaz interactiva que permite al usuario ingresar su ciudad de interés y la fecha planificada del viaje, obteniendo recomendaciones personalizadas y responsables.

ÍNDICE

RESUMEN EJECUTIVO.....	2
ÍNDICE	3
1. INTRODUCCIÓN.....	4
1.1. Antecedentes.....	4
1.2. Problemática	4
1.3. Objetivos	4
1.3.1. Objetivos Generales	4
1.3.2. Objetivos Específicos	4
2. RECURSOS	5
2.1. Metodologías	5
2.2. Fuentes de Datos	6
2.3. Herramientas y Tecnologías	7
3. IMPLEMENTACIÓN TÉCNICA DEL SISTEMA	8
3.1. Scraping	8
3.2. Análisis De Datos	9
3.3. Modelo Multimodal	15
3.3.1. Arquitectura del modelo	15
3.3.2. Dataset de entrenamiento	15
3.4. Entrenamiento y Evaluación.....	16
3.4.1. Configuración del entrenamiento	16
3.4.2. Resultados obtenidos.....	16
3.5. Sistema de Predicciones	18
3.6. Sistema de Recomendación e Interfaz.....	18
3.6.1. Lógica del Recomendador.....	18
3.6.2. Interfaz interactiva	19
3.7. Visualización Estratégica con Tableau.....	20
4. CONCLUSIONES Y RECOMENDACIONES	21
5. REFERENCIAS BIBLIOGRÁFICAS.....	22
6. ANEXOS	23

1. INTRODUCCIÓN

1.1. Antecedentes

España es uno de los destinos turísticos más relevantes a nivel mundial, situándose de forma constante entre los países líderes en llegada de turistas internacionales y en generación de ingresos por turismo (Organización Mundial del Turismo [OMT], 2022). Este sector representa una de las principales fuentes de riqueza del país, aportando de manera significativa al PIB y al empleo nacional (Instituto Nacional de Estadística [INE], 2023).

En paralelo, la digitalización ha transformado radicalmente la interacción entre empresas turísticas y consumidores. Las redes sociales, foros y plataformas de opinión se han consolidado como espacios donde los viajeros comparten experiencias y expectativas, generando un volumen masivo de información que influye en la toma de decisiones de futuros clientes (Xiang & Gretzel, 2010). Este tipo de *user-generated content* se ha convertido en una fuente clave para analizar la satisfacción del cliente, la percepción de marca y las tendencias de consumo en turismo (Mariani et al., 2018).

1.2. Problemática

La empresa TUI, líder global en servicios turísticos, enfrenta el desafío de adaptarse a un entorno caracterizado por la volatilidad de la demanda y la rapidez con la que circula la información digital. Aunque dispone de datos internos valiosos, la ausencia de un sistema que integre estas fuentes con datos externos abiertos —obtenidos mediante *web scraping* en redes sociales y foros— limita su capacidad de respuesta estratégica.

El reto no radica únicamente en la recopilación de información, sino en la extracción de conocimiento útil a partir de datos heterogéneos y no estructurados. La literatura señala que las organizaciones que implementan sistemas de análisis automatizado, basados en procesamiento del lenguaje natural (NLP) y modelos de *deep learning*, logran identificar patrones y anticipar tendencias con mayor precisión (Cambria et al., 2017; Hussain et al., 2022). Sin un enfoque de este tipo, TUI corre el riesgo de reaccionar de forma tardía ante cambios en la percepción del cliente o posibles crisis reputacionales en el mercado español.

1.3. Objetivos

1.3.1. Objetivos Generales

- Desarrollar un monitor de tendencias de opinión en el sector turístico español para la empresa TUI, utilizando técnicas de procesamiento del lenguaje natural (NLP) y modelos de aprendizaje profundo como XLM-RoBERTa-base, con el fin de anticipar cambios en la percepción de los clientes y apoyar la toma de decisiones estratégicas.
- Disminuir el impacto negativo del turismo masivo en ciudades saturadas, mediante la redistribución estratégica de los flujos turísticos hacia destinos alternativos que cuenten con buena reputación y menor afluencia de visitantes.
- Preservar la estabilidad y el crecimiento del sector turístico, mitigando los efectos de posibles conflictos sociales internos, con el fin de mantener su contribución significativa al Producto Interno Bruto (PIB) y al empleo nacional.

1.3.2. Objetivos Específicos

- Diseñar e implementar un proceso ETL para obtener información pública obtenida mediante web scraping en foros y redes sociales.

- Usar Azure AI Machine Learning Studio para la ejecución de los notebooks de modelos complejos con GPU.
- Preprocesar y normalizar los datos textuales para su análisis, incluyendo detección de idioma, eliminación de ruido y tokenización.
- Entrenar y ajustar un modelo de clasificación de opiniones basado en **XLM-RoBERTa-base**, capaz de identificar si una reseña es Molestia o No molestia tomando en cuenta la temporada del año.
- Generar predicciones de Molestia o No molestia para un nuevo grupo de datos extraídos de diferentes sitios web.
- Desarrollar una aplicación que recomiende destinos turísticos tomando en cuenta el nivel de turismo, reseñas y temporada del año.
- Diseñar e implementar un sistema de visualización interactiva de datos utilizando Tableau, que permita el análisis dinámico mediante filtros temáticos, geográficos y temporales, con el objetivo de facilitar la interpretación y toma de decisiones basada en la información disponible.
- Evaluar los resultados obtenidos en términos de utilidad práctica para TUI, destacando las implicaciones estratégicas, las limitaciones del modelo y posibles mejoras futuras

2. RECURSOS

2.1. Metodologías

El diseño del proyecto se estructura siguiendo la metodología **CRISP-DM** (Cross Industry Standard Process for Data Mining), ampliamente utilizada en proyectos de ciencia de datos por su enfoque iterativo y adaptable. Esta metodología permite abordar el problema desde una perspectiva integral, combinando la comprensión del negocio con el análisis técnico y la validación de resultados.

Las fases aplicadas en este proyecto son:




Diagrama CRISP-DM

1. Entendimiento del negocio: Se identificó la necesidad de mejorar la toma de decisiones turísticas mediante el análisis de reseñas reales, con el objetivo de ofrecer recomendaciones personalizadas y responsables.
2. Comprensión de los datos: Se evaluaron distintas fuentes de información, seleccionando plataformas como TripAdvisor y Reddit por su riqueza semántica y diversidad de opiniones.
3. Preparación de los datos: Se implementó un proceso de **ETL** (Extract, Transform, Load) mediante técnicas de web scraping, seguido de limpieza, traducción, normalización lingüística y balanceo de clases.
4. Modelado: Se entrenó un modelo multimodal basado en **XLM-RoBERTa-base**, que combina el análisis semántico de las reseñas con variables contextuales como destino turístico, mes y día de la semana.
5. Evaluación: Se aplicaron métricas como precisión, F1-score y matriz de confusión para validar el rendimiento del modelo en la clasificación binaria de sentimientos.
6. Despliegue: Se desarrolló una interfaz interactiva con Gradio que permite al usuario ingresar una ciudad y una fecha, obteniendo recomendaciones basadas en el nivel de saturación turística y la proporción de reseñas positivas.

Este diseño permite una implementación modular, escalable y replicable, adaptable a otros contextos turísticos o sectores que requieran análisis de opiniones y recomendaciones inteligentes.

2.2. Fuentes de Datos

Para la construcción de la base de datos utilizada en el entrenamiento del modelo de minería de texto, se realizó una recolección automatizada de reseñas públicas disponibles en TripAdvisor y Reddit, plataformas públicas y confiables recomendadas por TUI. Se tomaron medidas para respetar la privacidad de los usuarios, anonimizar los datos y limitar el impacto técnico sobre el sitio web. Esta actividad se llevó a cabo exclusivamente con fines académicos para el presente informe.

La recolección se realizó mediante técnicas de web scraping, organizadas bajo el paradigma ETL (Extract, Transform, Load):

1. Extract: Se desarrollaron scripts en Python utilizando librerías como *Selenium*, *BeautifulSoup* y *PRAW* para extraer contenido de páginas estáticas, dinámicas y APIs.
2. Transform: Se aplicaron rutinas de limpieza, normalización lingüística y traducción automática para estandarizar los textos.
3. Load: Los datos procesados se consolidaron en archivos CSV y se almacenaron en la nube de Azure para su posterior análisis.

El sistema de scraping fue diseñado de forma modular, permitiendo incorporar nuevas rutinas según el tipo de fuente. Además, se implementó la lectura automatizada de archivos de URLs, lo que facilitó la escalabilidad del proceso. Cada reseña recolectada contiene los siguientes campos estructurados:

- *Destination_City*: ciudad mencionada en la reseña
- *Language*: idioma original del texto
- *Rating*: puntuación otorgada por el usuario
- *Review_Text*: contenido textual de la reseña
- *Review_Date*: fecha de publicación

2.3. Herramientas y Tecnologías

Para el desarrollo del sistema se utilizaron herramientas especializadas en ciencia de datos, procesamiento de lenguaje natural y despliegue de aplicaciones interactivas. La elección de estas tecnologías respondió a criterios de escalabilidad, compatibilidad con entornos en la nube y facilidad de integración.

A. Entorno de desarrollo

- *PyCharm*: Entorno de desarrollo integrado (IDE) utilizado para la escritura, depuración y organización de los scripts en Python.
- *Google Colab*: Entorno de ejecución en la nube que permitió entrenar modelos de lenguaje y realizar análisis exploratorios con acceso a GPU.

B. Librerías y frameworks

- *Python*: Lenguaje principal del proyecto por su versatilidad y ecosistema de librerías.
- *Selenium* y *BeautifulSoup*: Automatiza la navegación y extraer contenido de páginas web estáticas y dinámicas.
- *PRAW*: Permite acceder a la API de Reddit y recolectar opiniones turísticas.
- *pandas*, *numpy*, *matplotlib*, *seaborn*, *plotly*: Permite manipulación de datos y visualización.
- *spaCy*, *nlTK*, *textacy*: Realiza procesamiento lingüístico, lematización y eliminación de ruido textual.
- *Transformers (Hugging Face)*: Permite el uso del modelo **XLM-RoBERTa-base** en tareas de clasificación de sentimientos.
- *scikit-learn*: Realiza balanceo de clases, codificación de variables y evaluación de métricas.
- *Gradio*: Permite construir interfaces web interactivas para modelos de machine learning. En este caso, se utiliza para visualizar los resultados del análisis emocional.

C. Infraestructura

- *Azure Cloud Storage*: Para el almacenamiento de los archivos CSV generados por el scraper y utilizados en el análisis.
- *Azure ML Pipelines*: Permite diseñar, automatizar y monitorear flujos de trabajo complejos en la nube, cada pipeline se compone de pasos que incluyen ejecución de scripts Python, preparación de datos, entrenamiento de modelos o despliegue de contenedores Docker. Facilita la trazabilidad, reproducibilidad y ejecución secuencial de tareas, además de permitir disparar eventos automáticamente por programación o por la llegada de nuevos datos.
- *Docker*: Permite crear contenedores, es decir, microentornos de cómputo que encapsulan todo lo necesario para ejecutar aplicaciones de forma consistente: sistema operativo, librerías, dependencias y scripts. En este proyecto se utiliza para ejecutar el scraper web y la aplicación de Gradio..

- *Azure AI Machine Learning Studio*: Permite ejecutar notebooks Jupyter, crear Jobs de orquestación y gestionar recursos de cómputo para tareas de machine learning y procesamiento de datos de modelos complejos con GPU

3. IMPLEMENTACIÓN TÉCNICA DEL SISTEMA

A continuación, se presenta el diagrama de flujo de la implementación técnica.




Diagrama de flujo de la Implementación Técnica del sistema


3.1. Scraping

El proceso de scraping se implementó como parte de una arquitectura modular y automatizada en la nube, diseñada para recolectar reseñas turísticas de forma eficiente y reproducible. La ejecución se realiza mediante scripts en Python encapsulados en contenedores *Docker*, que garantizan la portabilidad y consistencia del entorno de ejecución. Estos contenedores incluyen todas las dependencias necesarias y permiten ejecutar tanto el scraper web como una aplicación de visualización con *Gradio*.

La orquestación de tareas se lleva a cabo en *Azure ML Studio*, donde se configuran Jobs que activan los distintos componentes del flujo. El procesamiento intensivo —como limpieza, normalización y preparación de datos— se realiza en notebooks Jupyter, ejecutables tanto en Azure como en Google Colab, lo que aporta flexibilidad al entorno de desarrollo.

Los datos extraídos por el scraper se almacenan en Azure Storage en formatos estructurados, y se utilizan como entrada para los módulos de clasificación de emociones. La automatización completa del proceso se logra mediante *Azure ML Pipelines*, que permiten encadenar tareas de forma secuencial y disparar eventos por programación o en respuesta a la llegada de nuevos datos. Esto asegura una actualización continua del sistema sin necesidad de intervención manual.

Gracias a esta integración, el scraping se convierte en un componente robusto del flujo de trabajo, capaz de operar bajo demanda o de forma programada, optimizando recursos de cómputo y garantizando la trazabilidad y reproducibilidad del proceso.



Arquitectura del scraper

Esta arquitectura permitió la recolección eficiente de una gran cantidad de reseñas únicas, distribuidas geográficamente en múltiples ciudades españolas. La diversidad y volumen de los datos obtenidos constituyen una base sólida para el análisis de sentimientos y la posterior construcción del modelo de clasificación, asegurando representatividad y profundidad en el estudio del comportamiento turístico.

3.2. Análisis De Datos

Una vez recolectadas las reseñas turísticas, se procedió a su preprocesamiento con el objetivo de estandarizar el contenido textual y facilitar su análisis semántico. Este proceso fue fundamental para garantizar la calidad del corpus y mejorar el rendimiento del modelo de clasificación.

Los pasos aplicados fueron los siguientes:

1. Conversión de fechas: Se transformaron el campo Review_Date al formato datetime, permitiendo extraer variables temporales como mes y día de la semana.
2. Traducción automática: Dado que las reseñas estaban escritas en múltiples idiomas, se utilizó la librería deep-translator para traducir todos los textos al inglés, asegurando una base lingüística común para el análisis.
3. Limpieza textual: Se eliminaron espacios innecesarios, se convirtieron todos los caracteres a minúsculas y se normalizaron contracciones y expresiones informales.
4. Lematización y eliminación de ruido: Mediante el modelo en_core_web_sm de spaCy, se lematizaron los textos y se eliminaron puntuaciones, stopwords y tokens irrelevantes. El resultado se almacenó en el campo preprocessed_text.

5. Balanceo de clases: Después de eliminar los registros duplicados, se obtiene un porcentaje de datos en No molestia de 58% y en Molestia de 42%. Estamos en el límite para considerarlo razonablemente balanceado.






Gráfico de barras según clasificación de sentimiento



Gráficos de distribución de Ratings según sentimiento



WordClouds por clasificación de sentimiento




Gráfico de distribución de longitud de reseñas por sentimiento

Este preprocesamiento permitió construir un corpus limpio, balanceado y semánticamente enriquecido, listo para ser utilizado en el entrenamiento del modelo multimodal.


Antes de entrenar el modelo de clasificación, se realizó un análisis exploratorio de los datos con el objetivo de comprender mejor la distribución, el comportamiento y las características semánticas de las reseñas turísticas. Esta etapa permitió identificar patrones relevantes y validar la calidad del corpus procesado

Los principales hallazgos fueron:


1. Distribución geográfica: Se observó una alta concentración de reseñas en ciudades como Málaga, Bilbao, Córdoba y Alicante, lo que refleja su popularidad como destinos turísticos. Además, se identificó que las ciudades con peores percepciones son Zamora y Santa Cruz de Tenerife, mientras que las mejores son Melilla y Jaén.



Treemap de reseñas por ciudad



Ranking de ciudades con reseñas positivas



Ranking de ciudades con reseñas negativas

2. Diversidad lingüística: Aunque el corpus fue traducido al inglés, se identificaron más de 10 idiomas originales, siendo el español, inglés, italiano y francés los más frecuentes.




Gráfico de barras con la distribución por idioma

3. Tendencias temporales: El volumen de reseñas muestra picos positivos de demanda en 2016 y 2017, coincidiendo con el aumento de oferta de las aerolíneas Low cost, y un pico negativo durante 2020 y 2021, que se presumiblemente corresponde a la pandemia del COVID-19. Sin embargo, en los últimos años la demanda ha ido en aumento.

Por otra parte, el Rating promedio suele ser más alto en la temporada de primavera (marzo-junio), es posible que se deba a la presencia del fenómeno de turistificación, siendo este más visible en las ciudades durante los meses de verano.




Gráfico de barras de la evolución anual de reseñas y según sentimiento




Gráfico de líneas con el rating promedio por estación anual

4. Frecuencia de palabras clave: En las reseñas clasificadas como Molestia, predominan términos como “little”, “small”, “bad” y “time”. En contraste, las reseñas No molestia destacan palabras como “beautiful”, “great”, “nice” y “good”.




Gráfico de barras de frecuencia de palabras clave

5. Visualización semántica: Se aplicó reducción de dimensionalidad (PCA) sobre los embeddings generados por **XLM-RoBERTa-base**, lo que permitió observar una separación clara entre las dos clases.




Gráfico PCA de reseñas con color por Sentimiento

Este análisis exploratorio confirmó que las reseñas contienen información rica y estructurada, útil para entrenar un modelo de clasificación robusto y contextualizado.

3.3. Modelo Multimodal

El núcleo del sistema de recomendación se basa en un modelo de clasificación binaria que combina el análisis semántico de las reseñas con variables contextuales. Este enfoque multimodal permite capturar no solo el contenido textual, sino también el entorno temporal en el que se produce cada opinión.

3.3.1. Arquitectura del modelo


El modelo se construyó sobre la arquitectura **XLM-RoBERTa-base**, una variante multilingüe de **RoBERTa** desarrollada por Facebook AI, entrenada sobre 100 idiomas. Esta elección permite procesar reseñas originalmente escritas en distintos idiomas, incluso antes de su traducción al inglés.

Para enriquecer el análisis, se incorporaron variables contextuales codificadas como embeddings adicionales:

1. Destination_City: ciudad mencionada en la reseña
2. Mes: mes de publicación
3. Dia_Semana: día de la semana

Estas variables se integraron mediante un dataset personalizado (Multimodal Dataset) que combina los embeddings textuales generados por XLM-RoBERTa-base con los embeddings categóricos de las variables contextuales. La arquitectura final del modelo incluye:

- Capa de entrada textual (XLM-RoBERTa-base)
- Capa de entrada contextual (embeddings categóricos)
- Concatenación de ambas salidas
- Capa densa intermedia
- Capa de salida con activación sigmoide para clasificación binaria (Molestia / No molestia)



Arquitectura del Modelo Multimodal

3.3.2. Dataset de entrenamiento

El corpus final utilizado para el entrenamiento incluyó alrededor de 19231 reseñas balanceadas entre ambas clases. Cada muestra contenía el texto preprocesado, las variables contextuales codificadas y la etiqueta de sentimiento.

Este enfoque multimodal permitió mejorar la capacidad del modelo para identificar patrones de molestia no solo en el lenguaje, sino también en el contexto en que se expresan, lo que resulta especialmente útil en el ámbito turístico, donde la percepción puede variar según el destino turístico o el día de la visita.

3.4. Entrenamiento y Evaluación

Una vez definido el modelo multimodal, se procedió a su entrenamiento utilizando el framework *transformers* de *Hugging Face*, que permite integrar modelos de lenguaje pre entrenados con facilidad.

El proceso se llevó en dos etapas, la primera tomando una muestra del 10% y ejecutando en *Google Colab* para verificar que el programa se ejecute sin errores.

En la segunda etapa se ejecutó el modelo en *Machine Learning Studio de Azure AI* con acceso a GPU, lo que permitió acelerar los tiempos de cómputo y realizar ajustes iterativos.

3.4.1. Configuración del entrenamiento

Se utilizó el objeto *Trainer* para gestionar el ciclo de entrenamiento, con los siguientes parámetros:

- Batch size: 16
- Número de épocas: 3
- Early stopping: activado, con paciencia de 3 épocas
- Optimización: AdamW
- Evaluación: cada 50 pasos
- Métricas: Accuracy y F1-score.

El corpus fue dividido en conjunto de entrenamiento (80%) y validación (20%), asegurando una distribución balanceada entre las clases *Molestia* y *No molestia*.

3.4.2. Resultados obtenidos

El modelo alcanzó un rendimiento satisfactorio en la tarea de clasificación binaria, con las siguientes métricas:

```
trainer.evaluate(dataset_test)
[121/121 00:46]
{'eval_loss': 0.29775193333625793,
 'eval_accuracy': 0.908004158004158,
 'eval_f1_score': 0.8742004264392325,
 'eval_runtime': 47.0574,
 'eval_samples_per_second': 40.886,
 'eval_steps_per_second': 2.571,
 'epoch': 0.31185031185031187}
```

Tabla de métricas.

- Accuracy: el 90,8% de las predicciones fueron correctas.
- F1-score: 87,4%, representa un buen equilibrio entre el recall y la precisión.
- Evaluación de pérdida (Eval_Los): 0.297, indica que el modelo está haciendo predicciones con alta confianza.
- Número de épocas: 3
- Epoch: 0.311, indica que el modelo se detuvo temprano gracias al *Early Stopping* que se agregó.

Reporte de Clasificación:				
	precision	recall	f1-score	support
Molestia	0.97	0.79	0.87	776
No molestia	0.88	0.99	0.93	1148
accuracy			0.91	1924
macro avg	0.93	0.89	0.90	1924
weighted avg	0.92	0.91	0.91	1924

Reporte de Clasificación.

En la clase Molestia:


- Precisión: 0.97, indica que el modelo es muy confiable cuando predice que una reseña es molesta. Solo el 3% de esas predicciones son falsas.
- Sensibilidad: 0.79, indica que el modelo detecta el 79% de las reseñas que realmente son molestas. Sin embargo, se le escapa el 21% restante.
- F1-score: 0.87, indica que hay un buen equilibrio entre precisión y recall. El modelo tiene un rendimiento sólido en esta clase.

En la clase No molestia:

- Precisión: 0.88, indica que el modelo predice “No molestia” el 88% de las veces.
- Sensibilidad: 0.99, indica que el modelo tiene una muy buena capacidad para detectar reseñas que no molestan.
- F1-score: 0.93, indica que el modelo está bien ajustado para esta clase.

Métricas globales:

- Accuracy: 0.91, el modelo acierta en el 91% de los casos totales.
- Weighted avg: Todas las métricas están en el rango de 91–92%, lo que confirma que el modelo funciona bien en conjunto, sin que una clase domine excesivamente.



Matriz de confusión.

- La matriz de confusión muestra una buena capacidad para distinguir entre reseñas negativas y positivas.
- Verdaderos negativos: 1132 reseñas que realmente no molestan y fueron clasificadas correctamente.
- Falsos positivos: 16 reseñas que molestan, pero fueron clasificadas como “No molestia”.
- Falsos negativos: 161 reseñas que no molestan, pero fueron clasificadas como “Molesta”.
- Verdaderos positivos: 615 reseñas que molestan y fueron clasificadas correctamente.

Además, se guardó el modelo entrenado para su posterior despliegue en el programa de predicciones. Este modelo constituye el núcleo del sistema, permitiendo evaluar nuevas reseñas y alimentar el algoritmo de decisión turística.

3.5. Sistema de Predicciones

Habiendo previamente entrenado el modelo de clasificación, y en conjunto con los datos nuevos de scraping *Data_Scraping*; se procederá a alimentar al programa de Predicciones. El programa analizará las reseñas de los nuevos datos, los clasificará como ‘Molestia’ o ‘No Molestia’, para finalmente guardar todos los resultados del análisis en un archivo llamado *Prediction_values.csv*.

3.6. Sistema de Recomendación e Interfaz

Una vez entrenado el modelo de clasificación, se diseñó un sistema de recomendación que permite evaluar destinos turísticos en función de dos criterios principales: el nivel de saturación turística y la proporción de reseñas positivas. Este sistema se implementó como una función lógica que opera sobre dos fuentes de datos:

1. *Ciudades_Nivel_Turismo.csv*: contiene información sobre el grado de saturación turística de cada ciudad y sus coordenadas geográficas.
2. *Review_Data_Final.csv* y *Prediction_values.csv*: contiene las reseñas clasificadas como ‘Molestia’ o ‘No Molestia’, junto con la fecha y ciudad de publicación.

El archivo *Ciudades_Nivel_Turismo.csv* fue generado a partir de una lista base de ciudades, cruzada con datos oficiales de visitantes, pernoctaciones y notoriedad turística (INE, Exceltur y Frontur). Se aplicó un ajuste cualitativo según el atractivo cultural y patrimonial de cada destino (por ejemplo, Toledo, Córdoba y Granada obtienen mayor puntuación pese a tener menor infraestructura hotelera que Madrid o Barcelona). Posteriormente, se normalizó la data en una escala de 1 a 10, donde 10 representa máxima afluencia turística y 1 mínima. Las ciudades con puntuación entre 1 y 5 fueron clasificadas como “sin exceso turístico” (valor 0), mientras que aquellas entre 6 y 10 fueron marcadas como “con exceso turístico” (valor 1).

3.6.1. Lógica del Recomendador

El algoritmo sigue la siguiente secuencia:

1. El usuario ingresa una ciudad y una fecha planificada de viaje.
2. Se consulta si el destino tiene exceso de turismo ($\text{Exc_turismo} = 1$).
3. Si está saturado, se buscan ciudades cercanas con al menos un 30% de reseñas positivas en un rango de ± 36 meses desde la fecha ingresada.
4. Se calcula la distancia geográfica entre el destino original y las alternativas mediante la fórmula de Haversine.
5. Se recomienda la ciudad más cercana con buena reputación y baja saturación.
6. Si el destino no está saturado, se evalúa directamente la proporción de reseñas positivas para decidir si se recomienda o no.




Diagrama de flujo que represente la lógica del Recomendador.

3.6.2. Interfaz interactiva

Para facilitar el uso del sistema, se desarrolló una interfaz con *Gradio*, que permite al usuario ingresar los datos de forma sencilla y recibir una recomendación textual inmediata. La interfaz incluye:

- Campo de texto para ciudad.
- Campo de texto para fecha (YYYY-MM-DD).
- Salida textual con la recomendación generada por el sistema.

Captura de pantalla de la interfaz Gradio en funcionamiento.

Este sistema representa la aplicación práctica del modelo de análisis de sentimientos, ofreciendo una herramienta accesible que promueve decisiones turísticas más informadas y sostenibles.

Para facilitar el acceso a la aplicación desarrollada, se ha habilitado un enlace público: <http://20.238.236.41:7860/>, donde los usuarios pueden interactuar directamente con el modelo de clasificación de emociones a través de una interfaz construida con *Gradio*. Además, se incluye un

código QR que permite acceder rápidamente desde dispositivos móviles, promoviendo la accesibilidad y la difusión de la herramienta.




Código QR de acceso a la interfaz pública del modelo emocional

3.7. Visualización Estratégica con Tableau

Como complemento al sistema de recomendación y al análisis técnico del modelo, se ha desarrollado un dashboard interactivo en Tableau que permite explorar el análisis de los datos de *Reviews_Data_Final* y resultados de las predicciones de *Data_scraping* desde una perspectiva visual y estratégica. Esta herramienta está orientada a usuarios técnicos, analistas y responsables de toma de decisiones que deseen interpretar los datos de forma intuitiva y dinámica; permitiendo una perspectiva más empresarial.

El dashboard tiene como propósito:

- Visualizar la distribución geográfica de las reseñas por ciudad.
- Analizar la evolución temporal de los sentimientos turísticos.
- Identificar patrones de molestia por destino.
- Facilitar la comparación entre destinos saturados y no saturados.



Captura del dashboard en Tableau.

Esta visualización estratégica permite transformar los resultados del análisis en conocimiento accionable, facilitando la comunicación con stakeholders y la toma de decisiones basadas en datos.

4. CONCLUSIONES Y RECOMENDACIONES

A partir del desarrollo e implementación del sistema propuesto, se han obtenido resultados que permiten valorar su eficacia y potencial de expansión. Las siguientes conclusiones resumen los principales logros alcanzados:

- Se desarrolló un monitor de tendencias usando un modelado con XLM-RoBERTa-base que permite identificar si una reseña tiene Molestia o No molestia con una precisión del 88% y un f1 score del 93%.
- Se identificó ciudades que tienen potencial turístico no aprovechado por la demanda actual.
- Se aplicaron técnicas avanzadas de procesamiento de lenguaje natural y análisis multimodal para generar recomendaciones turísticas personalizadas.
- Se estructuró un flujo de trabajo sólido basado en la metodología CRISP-DM, desde la recolección automatizada de datos hasta el despliegue de un sistema interactivo de recomendación.
- El uso del modelo XLM-RoBERTa-base, junto con variables contextuales, permitió capturar tanto el contenido semántico como el entorno de las reseñas, aportando mayor inteligencia al sistema.
- Las recomendaciones generadas, basadas en la saturación turística y reputación percibida, promueven un turismo más sostenible y consciente.
- Las visualizaciones desarrolladas en Tableau facilitan la interpretación de resultados por parte de equipos técnicos y decisores.
- El sistema transforma opiniones individuales en conocimiento colectivo, sentando las bases para una nueva forma de entender el turismo desde la vivencia del viajero.
- Se creó una aplicación capaz de recomendar ciudades.

En función de estos hallazgos, se proponen las siguientes acciones para mejorar y ampliar el alcance del sistema:

- Mantener el scraper activo para actualizar el corpus periódicamente.
- Integrar el sistema en plataformas comerciales como agencias de viaje o motores de reserva.
- Escalar el modelo a otras regiones para ampliar su impacto.
- Documentar el pipeline ETL y establecer alertas de fallos.
- Evaluar el rendimiento en otros entornos cloud (AWS, GCP).
- Incorporar análisis de emociones, ironía y segmentación por tipo de viajero.
- Probar modelos alternativos como DistilBERT o BERTimbau.
- Implementar validación cruzada continua para mejorar la precisión.
- Diseñar dashboards simplificados para usuarios no técnicos.
- Realizar encuestas de satisfacción para validar la utilidad del sistema.

5. REFERENCIAS BIBLIOGRÁFICAS

- Cambria, E., Schuller, B., Xia, Y., & Havasi, C. (2017). New avenues in opinion mining and sentiment analysis. *IEEE Intelligent Systems*, 28(2), 15–21. <https://doi.org/10.1109/MIS.2013.30>
- Hussain, A., Cambria, E., & Ahmad, K. (2022). A survey on sentiment analysis using deep learning. *Artificial Intelligence Review*, 55(5), 3919–3963. <https://doi.org/10.1007/s10462-021-10010-2>
- Instituto Nacional de Estadística (INE). (2023). *Cuenta Satélite del Turismo de España*. <https://www.ine.es>
- Mariani, M., Di Felice, M., & Mura, M. (2018). Facebook as a destination marketing tool: Evidence from Italian regional destination management organizations. *Tourism Management*, 69, 307–320. <https://doi.org/10.1016/j.tourman.2018.06.003>
- Minube, Guías-Viajar, La Vanguardia, Tripadvisor, Rurismo, Musement y Reddit. (s.f.). Sitios web consultados para la recolección de datos turísticos mediante scraping. Recuperado el 1 de septiembre de 2025.
- Xiang, Z., & Gretzel, U. (2010). Role of social media in online travel information search. *Tourism Management*, 31(2), 179–188. <https://doi.org/10.1016/j.tourman.2009.02.016>
- Instituto Nacional de Estadística (INE). (2024). *Estadísticas de ocupación hotelera, viajeros y pernoctaciones por provincias y ciudades*. https://www.ine.es/dyngs/INEbase/es/categoria.htm?c=Estadistica_P&cid=12547355768
- Frontur (Turespaña / INE). (2024). *Encuesta de movimientos turísticos en fronteras: llegadas internacionales por comunidad autónoma y provincias*. https://www.ine.es/dyngs/INEbase/es/operacion.htm?c=Estadistica_C&cid=1254736176996&menu=ultiDatos&idp=1254735576863
- Exceltur. (2024). *Informes sobre destinos urbanos más visitados y rankings de competitividad turística*. <https://www.exceltur.org/>

6. ANEXOS

A continuación, se detallan los archivos que forman parte del proyecto y que estarán disponibles en el repositorio digital asociado del siguiente enlace:

<https://drive.google.com/drive/folders/1L9AIXmKSu3o8ZrGMD0jMWBjLatx2PHU-?usp=sharing>

Estos documentos permiten explorar en profundidad cada etapa del trabajo, desde la recolección de datos hasta la visualización y presentación de resultados:

- *Analisis_de_datos.ipynb* : Notebook con gráficos y análisis exploratorios. También cuenta con su versión .html.
- *Dashboard_Analisis_datos.html*: HTML que muestra las gráficas del notebook *Analisis_de_datos.ipynb*.
- *TFM_Modelo_v10.ipynb* : Notebook con el modelo final de clasificación emocional. También cuenta con su versión .html.
- *Predicciones.ipynb*: Notebook con el análisis y visualización de las predicciones del modelo. También cuenta con su versión .html.
- *Recomendador_de_Destinos_Turisticos.ipynb* : Notebook para la recomendación de destinos basada en emociones. También cuenta con su versión .html.
- *Data_Scraping.csv* : Datos brutos obtenidos mediante scraping.
- *Reviews_Data_Final_Analisis.csv* : Versión analítica del dataset con variables adicionales.
- *Reviews_Data_Final.csv* : Conjunto de datos estructurado con reseñas procesadas.
- *Predictions.values.csv* : Archivo con las predicciones generadas por el modelo.
- *Ciudades_Nivel_Turismo.csv* : Archivo de ciudades con clasificación de nivel turístico y coordenadas.
- *Presentacion_TFM_Reviews_Destinos.twbx* : Dashboard interactivo de datos de scraping en Tableau.
- *Presentacion_TFM_Prediction_values.twbx* : Dashboard interactivo de predicciones en Tableau.
- *WC_Reviews.png* : Nube de palabras generada a partir de las reseñas turísticas.
- *Dashboard_analisis_datos.html* : Visualización interactiva en formato web.
- *Scraper_HTM*: Carpeta que contiene el proyecto de raspado web en python, compuesto de varios módulos que buscan etiquetas web para extraer datos de diferentes sitios.
- *TFM_Model_v10GC*: Carpeta que contiene el modelo entrenado.